Московский государственный технический университет им. Н.Э. Баумана

Кафедра «Системы обработки информации и управления»

Лабораторная работа №4 по курсу «Методы машинного обучения»

«Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей»

Выполнил:

Ильин В.С. Группа ИУ5-22М

Описание задания

Цель лабораторной работы: изучение сложных способов подготовки выборки и подбора гиперпараметров на примере метода ближайших соседей.

Задание

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кросс-валидации. Проведите эксперименты с тремя различными стратегиями кросс-валидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кроссвалидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

- Ход выполнения лабораторной работы

- Выбор датасета

В качестве набора данных мы будем использовать набор данных по состоянию ходьбы человека - https://www.kaggle.com/vmalyi/run-or-walk. Датасет состоит из 88588 наборов значений взятых с акселерометра и гироскопа. Данные собирались на устройство iPhone 5с, который был закреплен на запястье человека(левое и правое). Информация о данных бралась каждые 10 секунд. Задача определения активности по электронным устройствам является актуальной для легкоатлетов.

```
from google.colab import drive, files
drive.mount('/content/drive')

Go to this URL in a browser: https://accounts.google.com/o/oauth2/auth?cli

Enter your authorization code:
...........
Mounted at /content/drive
```

```
from google.colab import files
import os
```

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
os.listdir()
data = pd.read_csv('drive/My Drive/mmo_datasets/row dataset.csv', sep=",")
total count = data.shape[0]
num cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0:
        num cols.append(col)
        temp perc = round((temp null count / total count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'
              .format(col, dt, temp null count, temp perc))
data cleared = data
uniquevalues = np.unique(data cleared['activity'].values)
uniquevalues
\Gamma array([0, 1])
data cleared.head(10)
```

 \Box date time username wrist activity acceleration x accele 2017-0 13:51:15:847724020 viktor 0 0 0.2650 6-30 2017-0.6722 13:51:16:246945023 0 0 viktor 6-30 2017-0.4399 2 13:51:16:446233987 viktor 0 0 6-30 2017-3 13:51:16:646117985 viktor 0 0 0.3031 6-30 2017-13:51:16:846738994 viktor 0 0 0.4814 6-30 2017-5 13:51:17:46806991 viktor 0 0 0.4044 6-30 2017-13:51:17:246767997 viktor 0 0 0.6320

train_test_split

6 20

```
data_cleared = data_cleared.drop('date', axis=1)
data_cleared = data_cleared.drop('time', axis=1)
data_cleared = data_cleared.drop('username', axis=1)
target = data cleared['activity']
data_cleared = data_cleared.drop('activity', axis=1)
```

₽		wrist	acceleration_x	acceleration_y	acceleration_z	gyro_x	gyro_y	g
	0	0	0.2650	-0.7814	-0.0076	-0.0590	0.0325	-
	1	0	0.6722	-1.1233	-0.2344	-0.1757	0.0208	
	2	0	0.4399	-1.4817	0.0722	-0.9105	0.1063	-
	3	0	0.3031	-0.8125	0.0888	0.1199	-0.4099	-
	4	0	0.4814	-0.9312	0.0359	0.0527	0.4379	
	5	0	0.4044	-0.8056	-0.0956	0.6925	-0.2179	
	6	0	0.6320	-1.1290	-0.2982	0.0548	-0.1896	
	7	0	0.6670	-1.3503	-0.0880	-0.8094	-0.7938	-
	8	0	0.2704	-0.8633	0.1293	-0.4173	-0.1904	-
	9	0	0.4690	-1.0740	0.0219	0.0388	1.1491	
<pre>from sklearn.model_selection import train_test_split X_train, X_test, Y_train, Y_test = train_test_split(data_cleared, target, test_size=0.2, random_state=1)</pre>								
X_train.shape, Y_train.shape								

▼ Обучение для произвольного параметра К

┌→ ((70870, 7), (70870,))

C→ ((17718, 7), (17718,))

X_test.shape, Y_test.shape

```
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
knn_model = KNeighborsClassifier(n_neighbors=5)
knn_model.fit(X_train, Y_train)
predicted = knn_model.predict(X_test)
predicted

☐ array([1, 0, 0, ..., 1, 1, 1])

from sklearn.metrics import accuracy_score
accuracy_score(Y_test, predicted)

☐ 0.9892200022575911
```

C→ 0.9893326136143525

```
# https://scikit-learn.org/stable/auto examples/model selection/plot confusion m
from sklearn.utils.multiclass import unique labels
from sklearn.metrics import confusion matrix
def plot_confusion_matrix(y_true, y_pred, classes,
                           normalize=False,
                           title=None,
                           cmap=plt.cm.Blues):
    This function prints and plots the confusion matrix.
   Normalization can be applied by setting `normalize=True`.
    if not title:
        if normalize:
            title = 'Normalized confusion matrix'
        else:
            title = 'Confusion matrix, without normalization'
   # Compute confusion matrix
    cm = confusion matrix(y_true, y_pred)
    # Only use the labels that appear in the data
    classes = classes[unique labels(y true, y pred)]
    if normalize:
        cm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]
        print("Normalized confusion matrix")
    else:
        print('Confusion matrix, without normalization')
    fig, ax = plt.subplots()
    im = ax.imshow(cm, interpolation='nearest', cmap=cmap)
    ax.figure.colorbar(im, ax=ax)
    # We want to show all ticks...
    ax.set(xticks=np.arange(cm.shape[1]),
           yticks=np.arange(cm.shape[0]),
           \# ... and label them with the respective list entries
           xticklabels=classes, yticklabels=classes,
           title=title,
           ylabel='True label',
           xlabel='Predicted label')
    # Rotate the tick labels and set their alignment.
    plt.setp(ax.get_xticklabels(), rotation=45, ha="right",
             rotation_mode="anchor")
    # Loop over data dimensions and create text annotations.
    fmt = '.2f' if normalize else 'd'
    thresh = cm.max() / 2.
    for i in range(cm.shape[0]):
        for j in range(cm.shape[1]):
            ax.text(j, i, format(cm[i, j], fmt),
                    ha="center", va="center", color="white" if cm[i, j] > thresh else "black")
    fig.tight layout()
    return ax
plot confusion matrix(Y test, predicted,
                       classes=np.array(['0', '1']),
```

title='Confusion matrix, without normalization')

Confusion matrix, without normalization
<matplotlib.axes._subplots.AxesSubplot at 0x7fa3b8420a20>

Confusion matrix, without normalization - 8000 - 7000 - 6000 - 5000 - 4000 - 3000

```
from sklearn.metrics import precision_score, recall_score, f1_score
(precision_score(Y_test, predicted, average='weighted'),
    recall_score(Y_test, predicted, average='weighted'))

□→ (0.9892836326099101, 0.9892200022575911)

f1_score(Y_test, predicted, average='weighted')

□→ 0.9892209305616176
```

Построение модели и оценка с помощью кросс-валидации

```
from sklearn.model selection import KFold, ShuffleSplit, StratifiedShuffleSplit
from sklearn.model selection import cross val score, cross validate
scoring = {'precision': 'precision_weighted',
            recall': 'recall weighted',
           'f1': 'f1 weighte\overline{d}'}
scores1 = cross validate(KNeighborsClassifier(n neighbors=2),
                         data cleared,
                         target,
                         scoring=scoring,
                        cv=KFold(n splits=3),
                         return_train_score=True
scores1
    {'fit_time': array([0.04464912, 0.04308128, 0.04944682]),
      score time': array([3.06341839, 3.10153389, 3.24147558]),
      'test_f1': array([0.98090209, 0.98762213, 0.93926346]),
      'test_precision': array([0.98150631, 0.98765269, 0.94727472]),
      'test_recall': array([0.98086692, 0.9876054 , 0.93816248]),
      'train f1': array([0.9902572 , 0.99190481, 0.99461045]),
      'train precision': array([0.9904395 , 0.99205678, 0.99466485]),
      'train recall': array([0.99026381, 0.99188947, 0.99461555])}
scores2 = cross validate(KNeighborsClassifier(n neighbors=2),
                         data_cleared,
                         target,
                         scoring=scoring,
                        cv=ShuffleSplit(n_splits=3, test_size=0.25),
                         return train score=True
                        )
scores2
```

```
\Gamma {'fit time': array([0.06723833, 0.05582952, 0.05907083]),
     'score time': array([2.28498197, 2.24624991, 2.25549293]),
     'test f1': array([0.98451163, 0.98514311, 0.98640819]),
     'test_precision': array([0.98484146, 0.98540694, 0.98662956]),
     'test recall': array([0.98451258, 0.98514471, 0.98640899]),
     'train f1': array([0.99143534, 0.99164624, 0.99098379]),
     'train precision': array([0.99158014, 0.99178417, 0.99114424]),
     'train recall': array([0.99143601, 0.99164672, 0.99098448])}
scores3 = cross validate(KNeighborsClassifier(n neighbors=2),
                       data_cleared,
                       target,
                       scoring=scoring,
                       cv=StratifiedShuffleSplit(n_splits=3, test_size=0.2),
                       return train score=True
scores3
\Gamma {'fit time': array([0.0589726 , 0.06245089, 0.06663036]),
     'score time': array([1.80771017, 1.81689453, 2.08004069]),
     'test f1': array([0.98526722, 0.98408184, 0.98453388]),
     'test precision': array([0.98557196, 0.9843833 , 0.98477332]),
     'test recall': array([0.98526922, 0.98408398, 0.9845355]),
     'train f1': array([0.99167443, 0.99195669, 0.99160387]),
     'train precision': array([0.99181146, 0.99208463, 0.99174321]),
     'train recall': array([0.9916749 , 0.9919571 , 0.99160435])}
0.97214457608351, 0.9856259853432557, 0.9849095262251883
```

Лучшую точность модели получилось достичь с использованием стратегии кросс-валидации KFold.

Подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации

```
GridSearchCV(cv=ShuffleSplit(n splits=2, random state=None, test size=0.25
           error score='raise-deprecating',
           estimator=KNeighborsClassifier(algorithm='auto', leaf size=30, metr
               metric params=None, n jobs=None, n neighbors=5, p=2,
               weights='uniform'),
           fit_params=None, iid='warn', n_jobs=None,
           naram drid-[]'n naidhhors': arrav/[ 2 /
                                                             g 101/11
clf gs.best params
□→ {'n neighbors': 8}
clf gs.best estimator
KNeighborsClassifier(algorithm='auto', leaf size=30, metric='minkowski',
               metric params=None, n jobs=None, n neighbors=8, p=2,
               weights='uniform')
plt.plot(n range, clf gs.cv results ['mean test score'])
    [<matplotlib.lines.Line2D at 0x7fa3b593dfd0>]
     0.98550
     0.98525
     0.98500
     0.98475
     0.98450
```

Сравнение качества обучения моделей

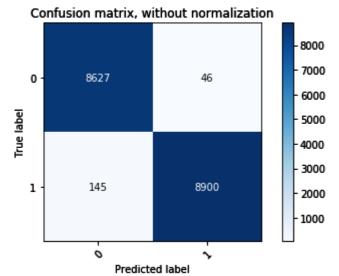
ś

0.98425

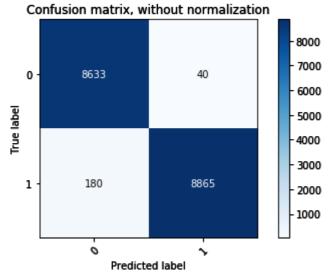
0.98400

10

Confusion matrix, without normalization <matplotlib.axes._subplots.AxesSubplot at 0x7fa3b58f97b8>



Confusion matrix, without normalization <matplotlib.axes._subplots.AxesSubplot at 0x7fa3b5b81a90>



```
(precision_score(Y_test, predicted, average='weighted'),
precision_score(Y_test, predicted_best, average='weighted'))

□ (0.9892836326099101, 0.9877091405373646)

(recall_score(Y_test, predicted, average='weighted'),
recall_score(Y_test, predicted_best, average='weighted'))

□ (0.9892200022575911, 0.9875832486736652)

(f1_score(Y_test, predicted, average='weighted'),
f1_score(Y_test, predicted_best, average='weighted'))

□ (0.9892209305616176, 0.9875845335729195)
```

Таким образом, подбор гиперпараметра позволил улучшить результаты оценки модели посредством всех представленных метрик.

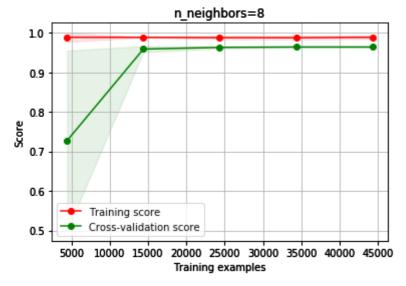
▼ Кривые обучения и валидации

```
from sklearn.model selection import learning curve, validation curve
def plot_learning_curve(estimator, title, X, y, ylim=None, cv=None,
                         n_jobs=None, train_sizes=np.linspace(.1, 1.0, 5)):
    plt.figure()
    plt.title(title)
    if ylim is not None:
        plt.ylim(*ylim)
    plt.xlabel("Training examples")
    plt.ylabel("Score")
    train_sizes, train_scores, test_scores = learning_curve(
    estimator, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
train_scores_mean = np.mean(train_scores, axis=1)
    train scores std = np.std(train scores, axis=1)
    test scores mean = np.mean(test scores, axis=1)
    test scores std = np.std(test scores, axis=1)
    plt.grid()
    plt.fill_between(train_sizes, train_scores_mean - train_scores_std,
                      train_scores_mean + train_scores_std, alpha=0.1,
color="r")
    plt.fill between(train sizes, test scores mean - test scores std,
                      test scores mean + test scores std, alpha=0.1, color="g")
    plt.plot(train sizes, train scores mean, 'o-', color="r",
             label="Training score")
    plt.plot(train_sizes, test_scores_mean, 'o-', color="g",
             label="Cross-validation score")
    plt.legend(loc="best")
    return plt
def plot validation curve(estimator, title, X, y,
                           param name, param range, cv,
                           scoring="accuracy"):
    train_scores, test_scores = validation_curve(
    estimator, X, y, param_name=param_name, param_range=param_range,
        cv=cv, scoring=scoring, n_jobs=1)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test scores mean = np.mean(test scores, axis=1)
    test scores std = np.std(test scores, axis=1)
    plt.title(title)
    plt.xlabel(param_name)
plt.ylabel("Score")
    plt.ylim(0.0, 1.1)
    lw = 2
    plt.plot(param range, train scores mean, label="Training score",
                  color="darkorange", lw=lw)
    plt.fill_between(param_range, train_scores_mean - train_scores_std,
                      train_scores_mean + train_scores_std, alpha=0.2,
color="darkorange", lw=lw)
    plt.fill_between(param_range, test_scores_mean - test_scores_std,
                      test_scores_mean + test_scores_std, alpha=0.2,
                      color="navy", lw=lw)
    plt.legend(loc="best")
    return plt
plot_learning_curve(KNeighborsClassifier(n_neighbors=8),
```

'n_neighbors=8',
data cleared,

```
target,
cv=2
```

<module 'matplotlib.pyplot' from '/usr/local/lib/python3.6/dist-packages/m</pre>



 $\begin{tabular}{ll} \leftarrow & $$\mbox{module 'matplotlib.pyplot' from '/usr/local/lib/python3.6/dist-packages/m '} \end{tabular}$

